

Winoground / Evaluating CLIP

Retrieval alto $\neq$ razonamiento composicional

Niels Victor Pacheco Barrios

Cuadernos C5 · C8 · C10


MCC225 — IA Generativa y Aprendizaje Multimodal · Examen Parcial 2026-1

Recordatorio: paper y resultado principal (2 min)

Winoground (Thrush et al., 2022): pares mínimos — 2 imágenes y 2 captions con *las mismas palabras en distinto orden*. Mide composición, no reconocimiento.

- **text / image / group score**; azar = $\frac{1}{4}, \frac{1}{4}, \frac{1}{6}$; humano $\approx 0,86$ group.
- **Evaluating CLIP**: una accuracy mayor no implica un modelo "mejor" (sesgos, diseño de clases).

Resultado: OpenCLIP tiene **Recall@K alto** pero **group score $\approx$ azar**.




Cómo lo obtuve ejecutando los cuadernos (3 min)

Reutilicé el **motor OpenCLIP del Cuaderno 10**: `create_model_and_transforms`, `encode imagen/texto`, similitud coseno.



1. `winoground_data.py`: real (HF, gated) + fallback curado.
2. `openclip_utils.py`: embeddings normalizados (C10).
3. `winoground_eval.py`: matriz 2×2 `sim[caption,imagen]` y los 3 scores.
4. `02_run_winoground.py`: scores + IC bootstrap + by-tag + ceguera + R@K.

```
text=1 ⇔ s(c0,i0)>s(c0,i1)
        y s(c1,i1)>s(c1,i0)
image=1 ⇔ s(c0,i0)>s(c1,i0)
        y s(c1,i1)>s(c0,i1)
group = text AND image
```

Verificación en vivo: los tres scores (3 min)



Mejora de código en vivo: ¿usa la imagen? y por tag (3 min)




Prueba de ceguera: real $\gg$ imágenes permutadas $\Rightarrow$ el modelo *sí* usa la imagen. Los errores son de **binding/relación**, no de reconocimiento.

Defensa crítica: limitaciones y mejora (2 min)

- **Limitación:** el group score mezcla *fallo composicional* con *ítems ambiguos* (Diwan et al.); el set curado es un proxy controlado, no el benchmark oficial.
- **Métrica:** azar del group = $1/6$ (no $1/16$): text e image no son independientes.
- **Sesgo:** sensibilidad a empates y a la normalización de embeddings.
- **Mejora:** evaluar un **cross-encoder** / **fusión profunda (C5)** y re-ranking con interacción cruzada (C6); versionar embeddings (DVC) para reproducibilidad total.

Backup: comparación de checkpoints



Backup: casos de error

Casos de error (group=0): pares mínimos que el modelo confunde

img0 -> «an old person kisses a young person»



img1 -> «a young person kisses an old person»



img0 -> «the taller person hugs the shorter person»



img1 -> «the shorter person hugs the taller person»



img0 -> «the masked wrestler hits the unmasked wrestler»



img1 -> «the unmasked wrestler hits the masked wrestler»

