

Winoground / Evaluating CLIP

El retrieval alto no implica razonamiento composicional

Niels Victor Pacheco Barrios

MCC225 — IA Generativa y Aprendizaje Multimodal · Examen Parcial 2026-1
Cuadernos C5 · C8 · C10

Qué voy a defender en 15 minutos

1. El problema: ¿CLIP *entiende* o solo *empareja*? (Winoground)
2. Cómo lo medí reutilizando el motor OpenCLIP del Cuaderno 10.
3. El resultado: retrieval alto, **group score $\approx$ azar**.
4. Verificación en vivo + validación contra los scores oficiales.
5. Por qué pasa (C5, C8), limitaciones y mejora.

Tesis en una frase: **recuperar bien una imagen no prueba que el modelo entienda el orden ni las relaciones de la escena.**

El problema

Mi tema: dos papers que cuestionan a CLIP

Winoground (Thrush et al., 2022)

¿Los modelos visión-lenguaje razonan de forma *composicional*, o reconocen objetos sueltos? Mide el orden y la vinculación, no el reconocimiento.

Evaluating CLIP (Agarwal et al., 2021)

Una accuracy mayor no define un modelo «mejor»: el diseño de clases y los prompts esconden sesgos. La métrica no lo es todo.

Ambos atacan la misma idea: **una buena métrica puede ocultar que el modelo no entiende.**

El núcleo de Winoground: el par mínimo

Dos imágenes y dos captions con **exactamente las mismas palabras en distinto orden**.

Caption 0 «*an old person kisses a young person*»

Caption 1 «*a young person kisses an old person*»

Mismo vocabulario. Distinguir las exige saber *quién* hace *qué* a *quién*. Un modelo que solo detecta «old», «young», «kiss» no puede; necesita composición.

400 ejemplos, etiquetados por tipo de cambio: **Object, Relation, Both**.

Por ejemplo, similitud $s(\text{caption}, \text{imagen})$ en una matriz 2×2 :

	i_0	i_1
c_0	s_{00}	s_{01}
c_1	s_{10}	s_{11}

(la diagonal verde es lo correcto)

text score: fijada cada imagen, ¿gana el caption correcto?

$$s_{00} > s_{10} \text{ y } s_{11} > s_{01}$$

image score: fijado cada caption, ¿gana la imagen correcta?

$$s_{00} > s_{01} \text{ y } s_{11} > s_{10}$$

group score: ambas a la vez (text y image).

Detalle fino: el azar del group score es $1/6$

- text e image **no son independientes**: comparten las 4 similitudes.
- $\text{group} = 1$ exige que *ambas* diagonales superen a *ambas* off-diagonales.
- De las $4! = 24$ ordenaciones de 4 valores, solo **4** cumplen $\Rightarrow 4/24 = 1/6 \approx 0,167$.

No es $1/16$. Comparar contra el baseline correcto es parte de la métrica (un error común que un examinador puede preguntar).

¿Un buen **Recall@K** (recuperación) implica **razonamiento composicional**?

Voy a mostrar que **no**: el mismo modelo, sobre el mismo conjunto, recupera bien y
falla la composición.

Cómo lo medí (Cuaderno 10)

Cómo funciona CLIP: un dual-encoder contrastivo

- Dos torres separadas: una codifica la imagen, otra el texto.
- Cada modalidad colapsa en **un único vector global**; se comparan por **coseno**.
- Entrenado con aprendizaje contrastivo (acercar pares correctos, alejar incorrectos).

Esto es exactamente el motor del **Cuaderno 10** (OpenCLIP): `create_model_and_transforms`, `encode_image/encode_text`, similitud coseno. Lo reutilicé tal cual.

Por qué un dual-encoder falla la composición

- Un vector global se comporta como «**bolsa de conceptos**».
- «old», «young», «kiss» activan dimensiones parecidas *estén como estén compuestos*.
- No hay interacción *token-a-token* entre palabras y regiones.

Conexión C5 / C8:

La *fusión profunda* (MMBT, C5) y la *atención crossmodal* (C8) sí dejan interactuar tokens visuales y textuales.
Esa es la vía para la composición.

El pipeline (reproducible)

1. `winoground_data.py`: Winoground real (HF, gated) o set curado offline.
2. `openclip_utils.py`: embeddings L2-normalizados (motor C10).
3. `winoground_eval.py`: matriz 2×2 y los 3 scores.
4. `metrics.py`: Recall@K, intervalos bootstrap.
5. `blindness_probe.py`: ¿usa la imagen? · `error_analysis.py`: por tag.

Todo determinista (semillas), versionado y con tests. Una corrida: `make run`.

El bloque clave: el scorer

```
def text_correct(sim):    # fija imagen, elige caption
    return sim[0,0] > sim[1,0] and sim[1,1] > sim[0,1]

def image_correct(sim):   # fija caption, elige imagen
    return sim[0,0] > sim[0,1] and sim[1,1] > sim[1,0]

def group_correct(sim):
    return text_correct(sim) and image_correct(sim)
```

Es el código **oficial** de Winoground. La redacción verbal de papers de seguimiento suena al revés; me guíé por el código y lo validé numéricamente.

¿Cómo sé que mi scorer no está mal?


Lo apliqué a los scores oficiales de CLIP que vienen en el propio dataset (statistics/model_scores/clip.jsonl).

	text	image	group
Paper (CLIP ViT-B/32)	0.3075	0.1050	0.0800
Mi scorer	0.3075	0.1050	0.0800

Coincidencia exacta. `python scripts/validate_against_official.py`

Resultados

Resultado principal: los tres scores




ViT-B-32/laion2b, 400 ejemplos reales. text=0.35, image=0.11, group=0.075 (azar 0.167; humano 0.86).

- **text** (0.35) está *por encima* del azar (0.25): el modelo capta algo.
- **group** (0.075) está *por debajo* del azar (0.167).
- No significa «peor que aleatorio» en general. Es la **asimetría text** $\gg$ **image**: acierta una dirección y falla la otra, y el group exige ganar las dos.


El intervalo de confianza del group (bootstrap 95 %: [0,05, 0,10]) queda **entero por debajo** del azar.

La evidencia de la tesis: retrieval alto, group bajo




Mismo modelo y mismo conjunto: **R@5=0.67**, **R@10=0.77** pero **group=0.075**. El retrieval usa toda la galería (fácil); el group exige ganar el par mínimo (difícil).

¿Qué tipo de error? Análisis por tag



Relation es lo más difícil (group 0.047). Son fallos de *vinculación* (quién con quién), no de reconocimiento. «Both» sube porque las dos imágenes difieren más.


¿El modelo usa la imagen? Prueba de ceguera



Permutó las imágenes entre ejemplos y recalculó. Los scores reales (0.35 / 0.11 / 0.075) **caen** a (0.14 / 0.04 / 0.02).

Conclusión: **sí usa la imagen**; su límite es composicional, no perceptivo. Es la versión cuantitativa de la pregunta de interpretabilidad de **C8**.

¿Y si uso un modelo más grande?



Group no mejora de forma monótona (0.075 / 0.072 / 0.085) y el **text incluso baja** con el modelo mayor (0.35 $\rightarrow$ 0.30 $\rightarrow$ 0.29). Escalar tamaño/datos **no** resuelve la composición.

Casos de error concretos (group = 0)



Pares mínimos que el modelo confunde: reconoce los objetos pero no su composición.

Cierre

Reproducibilidad (lo que pide el examen)

- Entorno fijo: `uv + uv.lock`, Python 3.12.
- Imagen **Docker** CPU; `Makefile`.
- Semillas globales; `env_logging` (hoja de trazabilidad).
- **16 tests** (pytest) + validación contra `clip.jsonl`.
- **CI** en GitHub Actions (push + nocturno).
- Evidencia (métricas/figuras) commiteada.
- Reproducir de cero:
`make setup && make all`.

El dataset gated **no** se redistribuye (licencia); cae al set curado si no hay acceso.

Verificación en vivo (lo que mostraré en pantalla)

1. Celda 1 del notebook: hoja de trazabilidad (versiones, git, dispositivo).
2. Celda del scorer: imprime la matriz 2×2 y text/image/group de un par.
3. `scores.json` + figura `scores_vs_chance.png`.
4. `python scripts/validate_against_official.py` → reproduce los scores oficiales.
5. Mejora en vivo: cambiar un *prompt*/consulta o añadir un par y re-ejecutar.

Lo pesado (`make run`) va pre-ejecutado; en vivo solo corro lo que tarda segundos.

- El group bajo **mezcla** fallo composicional con ítems ambiguos o difíciles (Diwan et al., «Why is Winoground Hard?»).
- Las métricas son comparaciones estrictas: **sensibles a empates** y a la normalización.
- R@K y accuracy **no miden composición**: necesarias, no suficientes.
- El set curado offline es un *proxy* sintético (OOD para CLIP).

- Evaluar un **cross-encoder** / **fusión profunda** (C5) y **re-ranking** con interacción cruzada (C6): la arquitectura que sí puede componer.
- Versionar embeddings (DVC) para reproducibilidad total de datos.
- Ampliar a más prompts, checkpoints y a *prompt ensembles* (C10).

Lo que **no** aseguro aún: que un cross-encoder lo resuelva. Es mi hipótesis, no un resultado medido.

- **C10:** motor OpenCLIP (embeddings, coseno, checkpoints, FAISS).
- **C5:** dual-encoder vs fusión profunda — *por qué* falla.
- **C8:** atención crossmodal / interpretabilidad — la prueba de ceguera.

El retrieval alto **no** implica razonamiento composicional.

Lo medí, lo validé y lo expliqué de forma reproducible.

Niels Victor Pacheco Barrios

Winoground / Evaluating CLIP · Cuadernos C5 · C8 · C10

github.com/nielspac177/Winoground-Evaluating-CLIP-MCC225

¿Preguntas?

Backup: referencias

- Thrush et al. (2022). *Winoground*. CVPR.
- Diwan et al. (2022). *Why is Winoground Hard?* EMNLP.
- Radford et al. (2021). *CLIP*. ICML.
- Agarwal et al. (2021). *Evaluating CLIP*.